Proceso KDD aplicado a la predicción del riesgo de diabetes

Jorge Luis Ortiz Libreros, Joshua Iván Olivares Blanco, Fabiola López Velázquez

1. Introducción

La diabetes es una de las enfermedades crónicas de mayor crecimiento a nivel mundial y su detección oportuna depende en gran medida de identificar a tiempo a los pacientes en riesgo. Factores como la glucosa en ayunas, la hemoglobina glucosilada, la edad, el peso corporal y los hábitos de vida están directamente relacionados con la probabilidad de desarrollarla. En este trabajo se analiza un conjunto de datos de pacientes con el fin de descubrir qué variables están más asociadas al riesgo de diabetes (Low, Moderate, High) y construir un modelo que permita clasificar a nuevos pacientes según ese riesgo, usando un árbol de decisión como herramienta de predicción.

2. Selección de los datos

La base de datos utilizada es diabetes_risk.csv, con 15,000 registros y 19 variables por paciente. La variable objetivo es diabetes_risk, de tipo categórico con tres niveles: Low, Moderate y High.

Tipo de variable	Ejemplos
Demográficas	age, gender, city, income_bracket
Clínicas / biométricas	bmi, fasting_blood_sugar, hba1c_level, blood_pressure_systolic/diastolic, waist_circumference_cm
Hábitos y estilo de vida	physical_activity_level, diet_type, smoking_status, alcohol_consumption, hours_sleep_per_night, stress_level
Antecedentes	family_history_diabetes
Variable objetivo	diabetes_risk (Low / Moderate / High)

La columna patient_id se descartó desde la selección porque es un identificador único que no aporta capacidad predictiva.

3. Limpieza de datos

Antes de construir el modelo se revisó la calidad de los datos:

- Duplicados: no se encontraron registros duplicados.
- Valores faltantes: se detectaron datos ausentes en tres variables categóricas — smoking_status (472 casos), alcohol_consumption (3,788 casos) e income_bracket (463 casos).
- Tratamiento de faltantes: al ser variables categóricas, los valores NA se reemplazaron por la categoría "Unknown" en lugar de eliminar los registros, para no perder información de las demás variables.
- Identificador: se eliminó la columna patient_id por no aportar valor predictivo.

4. Transformación de los datos

Las variables categóricas (gender, city, family_history_diabetes, physical_activity_level, diet_type, smoking_status, alcohol_consumption, income_bracket) y la variable objetivo (diabetes_risk) se convirtieron a tipo factor, formato requerido por el algoritmo de árbol de decisión en R. Después de la transformación, la variable objetivo mostró la siguiente distribución:

Categoría	Proporción
Low	60.0%
Moderate	25.0%
High	15.0%

La base se dividió en 70% para entrenamiento y 30% para prueba, usando muestreo estratificado (createDataPartition) para conservar esta proporción en ambos conjuntos.

5. Minería de datos

Se aplicó un árbol de decisión (algoritmo CART, función rpart de R) para clasificar el riesgo de diabetes a partir de las demás variables. Parámetros usados: cp = 0.001, minsplit = 20, maxdepth = 4. El árbol inicial se podó seleccionando el valor de complejidad (cp) con el menor error de validación cruzada, obteniendo el árbol final que se muestra a continuación.

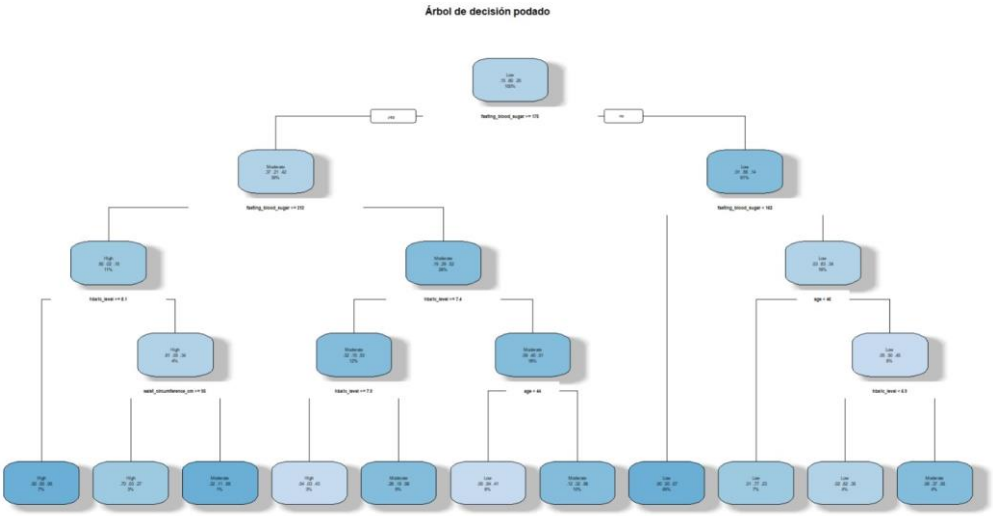


Fig1. Árbol de decisión podado para la predicción del riesgo de diabetes

La variable que primero divide el árbol es fasting_blood_sugar (glucosa en ayunas), seguida de hba1c_level (hemoglobina glucosilada), age (edad) y waist_circumference_cm (circunferencia de cintura), lo que coincide con los criterios clínicos habituales para evaluar el riesgo de diabetes.

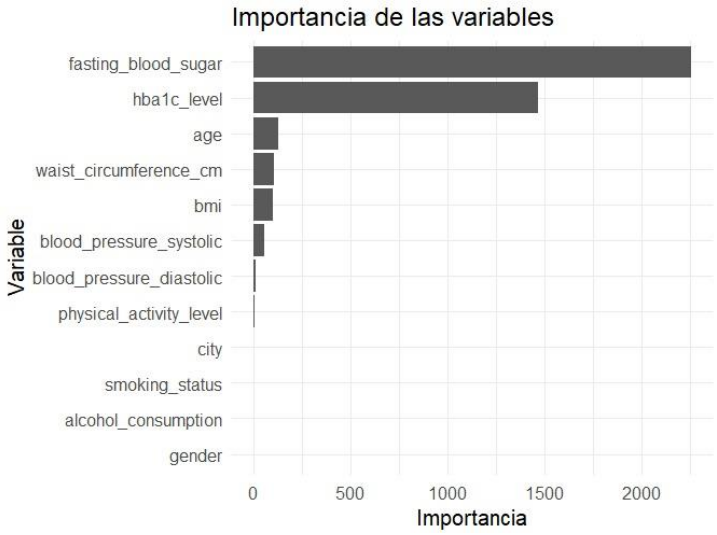


Fig 2. Importancia de las variables

6. Interpretación y evaluación de resultados

El desempeño del árbol podado se evaluó con los datos de prueba mediante una matriz de confusión, de la cual se obtuvo la exactitud (accuracy) global del modelo. Adicionalmente se calcularon métricas por categoría (sensibilidad, especificidad) y la importancia relativa de cada variable en la predicción.

De acuerdo con el árbol resultante, el conocimiento extraído es el siguiente:

- La glucosa en ayunas (fasting_blood_sugar) es el factor más determinante: valores muy altos (≥175, y en particular ≥212) concentran la mayoría de los casos de riesgo Alto.
- Entre los pacientes con glucosa moderada o baja, el nivel de HbA1c es el segundo criterio más relevante para distinguir riesgo Moderado de riesgo Bajo.
- La edad y la circunferencia de cintura afinan la clasificación dentro de los grupos de riesgo Bajo y Moderado, siendo un patrón consistente con el perfil de riesgo metabólico.

Este conocimiento puede usarse como apoyo (no diagnóstico) para priorizar pacientes que requieren seguimiento clínico, reforzando la importancia del control de la glucosa y la hemoglobina glucosilada como indicadores tempranos de riesgo.

7. Conclusión

El análisis realizado muestra que es posible construir un modelo interpretable capaz de clasificar el riesgo de diabetes de un paciente a partir de variables clínicas y de estilo de vida fácilmente medibles. El árbol de decisión resultante confirma lo que la literatura médica ya señala: la glucosa en ayunas y la hemoglobina glucosilada (HbA1c) son los indicadores más determinantes, seguidos de la edad y la circunferencia de cintura, que reflejan el riesgo metabólico general del paciente. Esto significa que, incluso sin exámenes exhaustivos, con unos cuantos datos accesibles se puede tener una primera aproximación confiable del nivel de riesgo de una persona.

Más allá del resultado técnico, este trabajo deja ver el valor de aplicar un proceso ordenado como el KDD: partir de datos crudos, con valores faltantes e inconsistencias, y llegar a conocimiento útil y accionable requiere pasar necesariamente por la limpieza, la transformación y la validación del modelo, no solo por el algoritmo de minería de datos. Un modelo como este podría emplearse como una herramienta de apoyo para el personal de salud, ayudando a priorizar a los pacientes que requieren seguimiento o estudios más profundos, sin que esto sustituya en ningún momento un diagnóstico médico formal. Como trabajo futuro, sería valioso comparar este árbol de decisión con otros algoritmos de clasificación (por ejemplo, random forest o regresión logística) para verificar si es posible mejorar la exactitud sin perder la interpretabilidad que hace tan útil a este tipo de modelo.